

# Illuminating Artistic Intuition

Exploring Zero-Shot Image Classification and  
Explainable AI through Diffusion Models and the  
LIME Algorithm

Leonardo Loureiro Costa

# Introdução

# Classificação de pinturas

# Objetivos

# Explorar **complete** zero-shot learning

## Prompt Engineering

Analisar a viabilidade de gerar conteúdos verossímeis com modelos de difusão por meio de LLM e Prompt Engineering

## Explainable AI

Quais regiões das pinturas de um determinado artista são mais importantes para a classificação de quadros seguinte o seu estilo?

## Data augmentation

Investigar se é viável utilizar imagens sintéticas geradas com a metodologia desse trabalho como uma técnica de Data augmentation

# Proposta

# Proposta

01 >>>

Geração de  
descrições de  
cena

02 >>>

Prompt  
Engineering para  
Stable Diffusion

03 >>>

Aprendizado e  
complete zero-  
shot learning

04

LIME e Explainable  
AI

01

# Descrição de cena

"You will act as a painting motif generator. I will provide you with a painting genre, such as still life, landscape, or portrait. Your task is to generate {numberOfExamples} examples of what to paint within that genre"



Religious Painting, 1 example

"A young child holding a teddy bear"

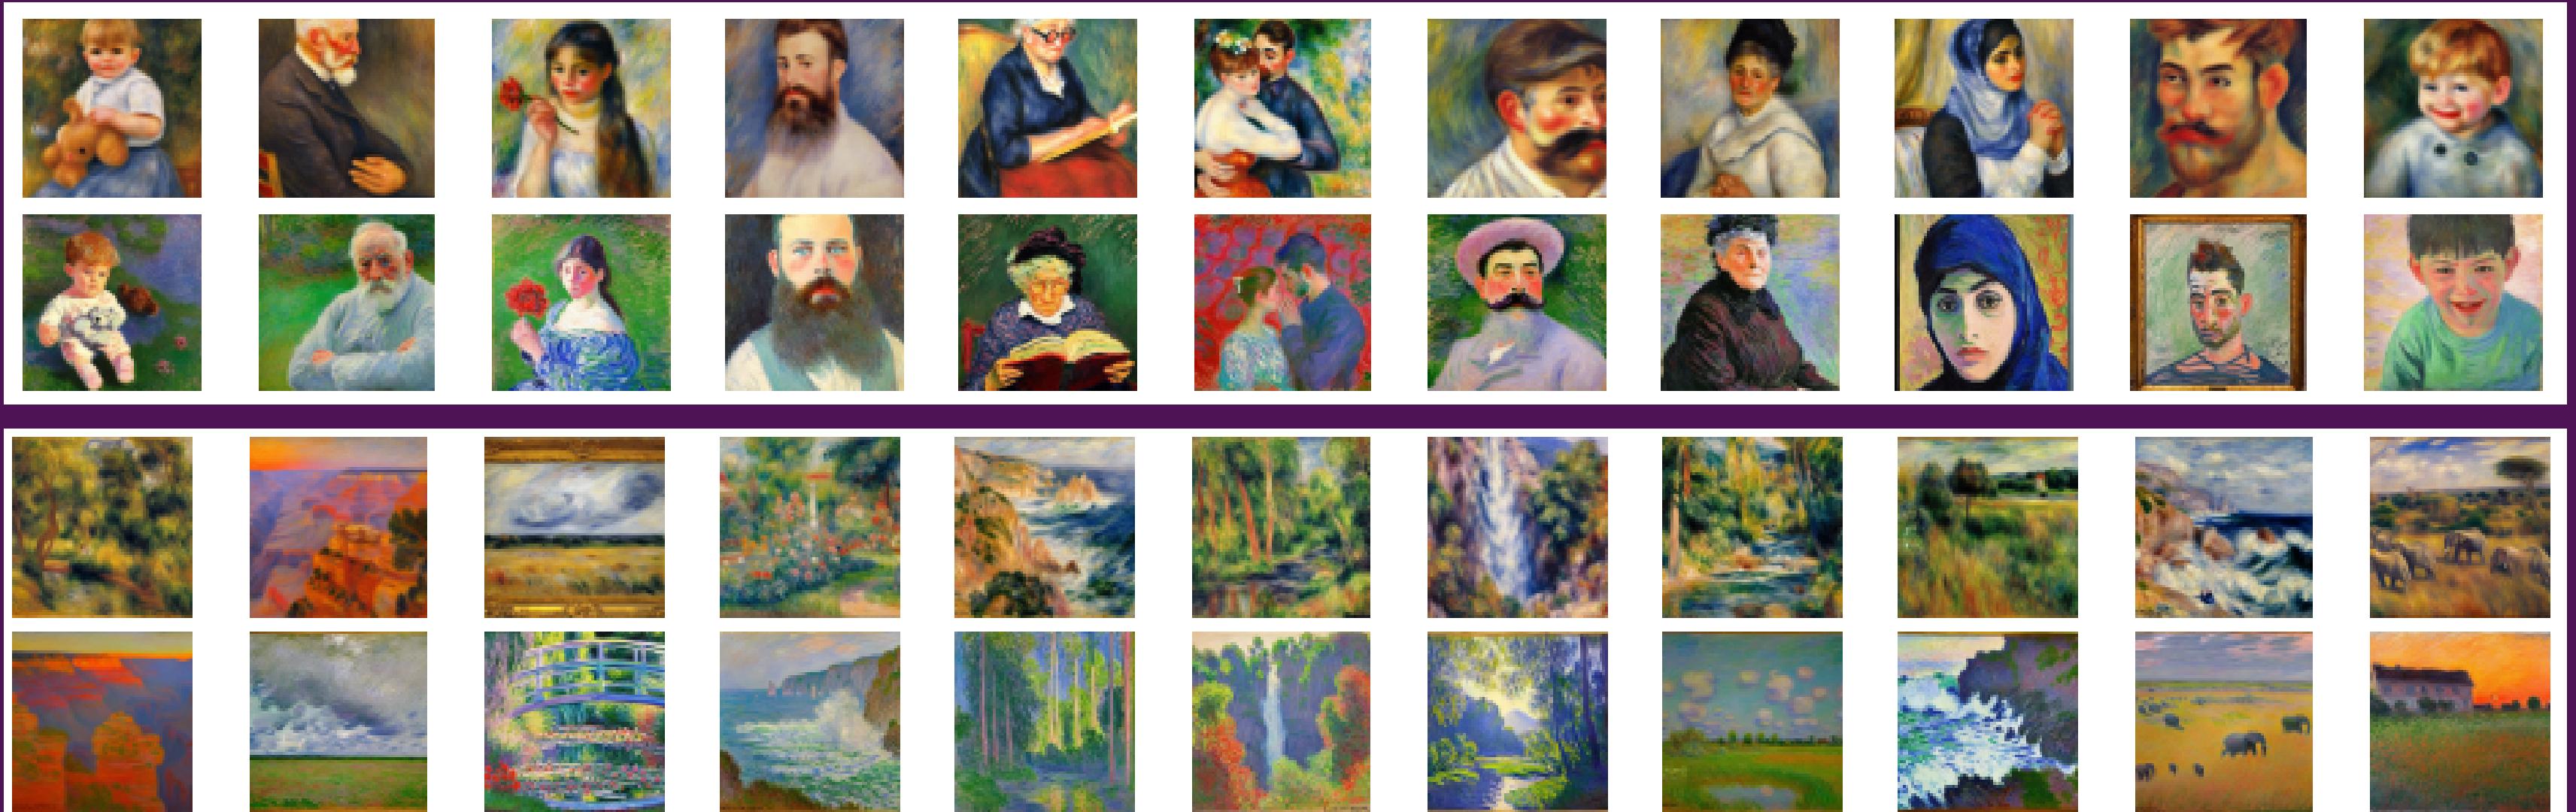
02

# Prompt Engineering



02

# Prompt Engineering



03

# Aprendizado e complete zero-shot

## Treino da EfficientNet B1 em 3 casos

- Imagens reais
- Imagens sintéticas
- Imagens reais junto com imagens sintéticas

04

## LIME e Explainable AI

Gerar mapas de calor das regiões mais importantes para classificar cada imagem do conjunto de teste.

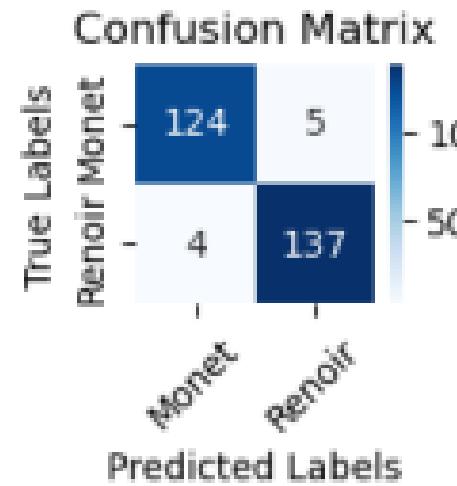
# Metodología experimental

# Metodologia experimental

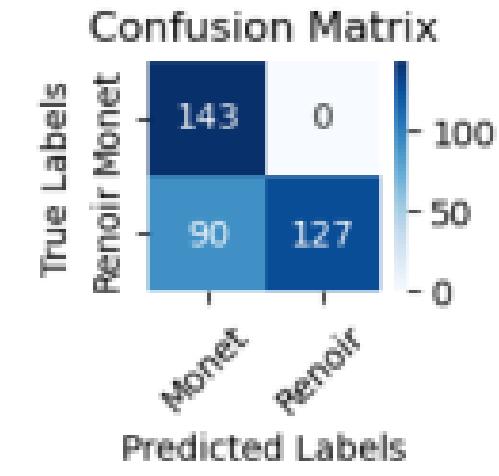
- Geração do dataset sintético, com mais de 3600 imagens
- Separação do conjunto de dados em Treino - Validação - Teste na proporção 80 - 10 - 10.
- Treino da EfficientNet B1 em 50 épocas de batch size 32 nos 3 tipos diferentes de dados
- Predição de imagens reais e sintéticas - Análise com o LIME
- Construção dos mapas de calor.

# Resultados e discussão

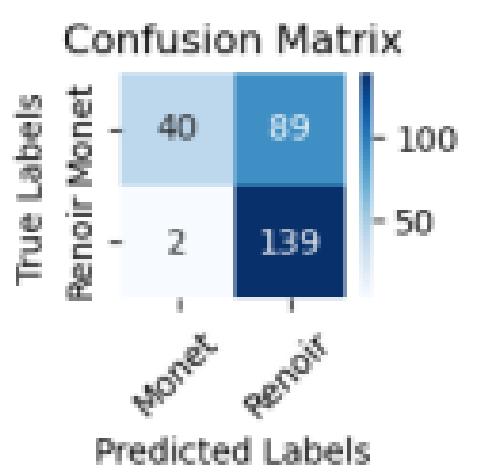
# Matrizes de confusão



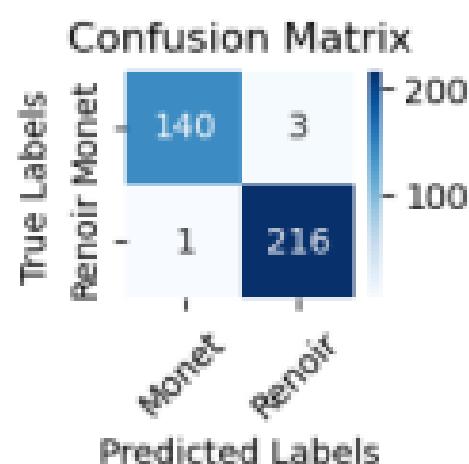
(a) Training in **real** images and testing in **real**



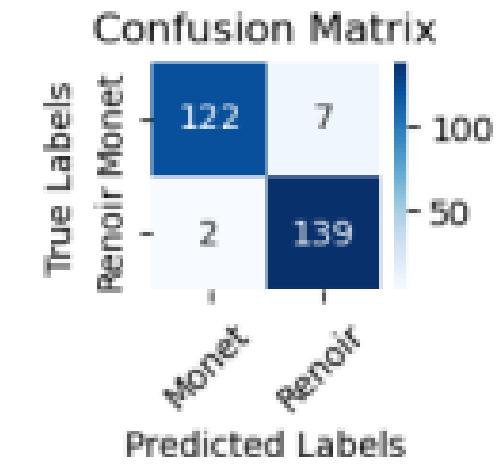
(b) Training in **real** images and testing in **synthetic**



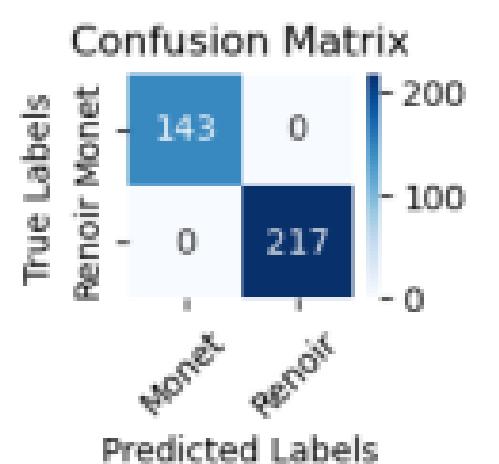
(c) Training in **synthetic** images and testing in **real**



(d) Training in **synthetic** images and testing in **synthetic**

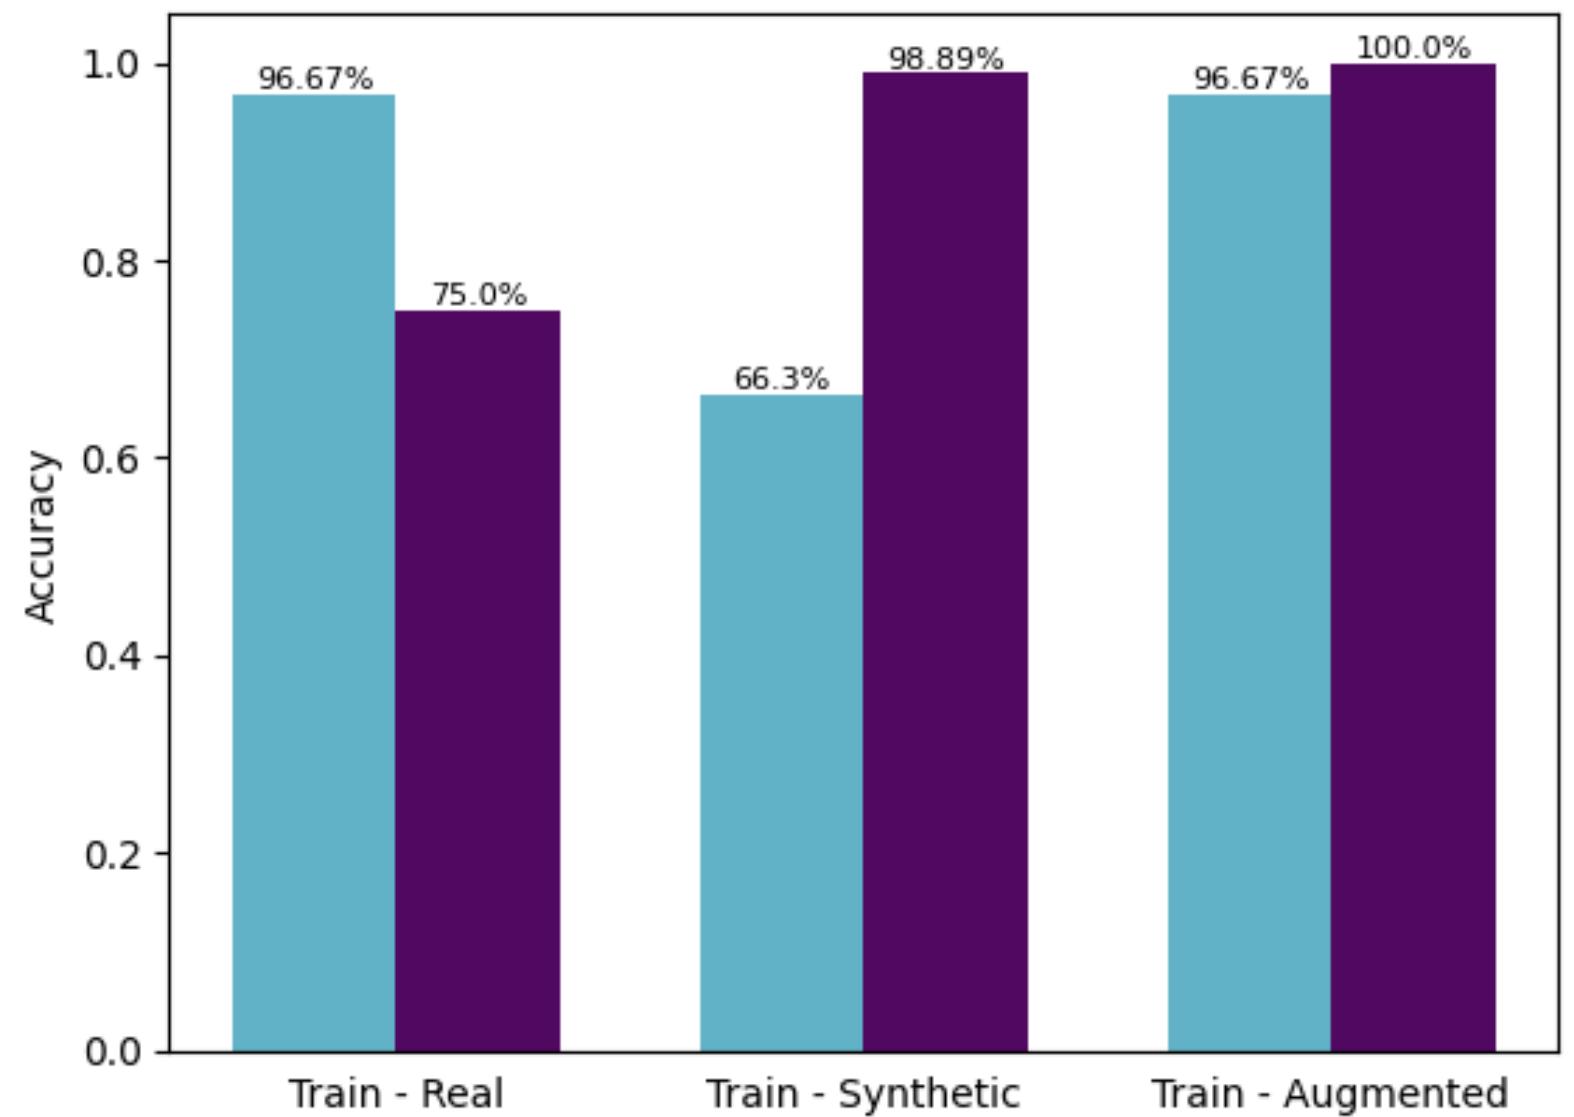


(e) Training in **augmented** images and testing in **real**



(f) Training in **augmented** images and testing in **synthetic**

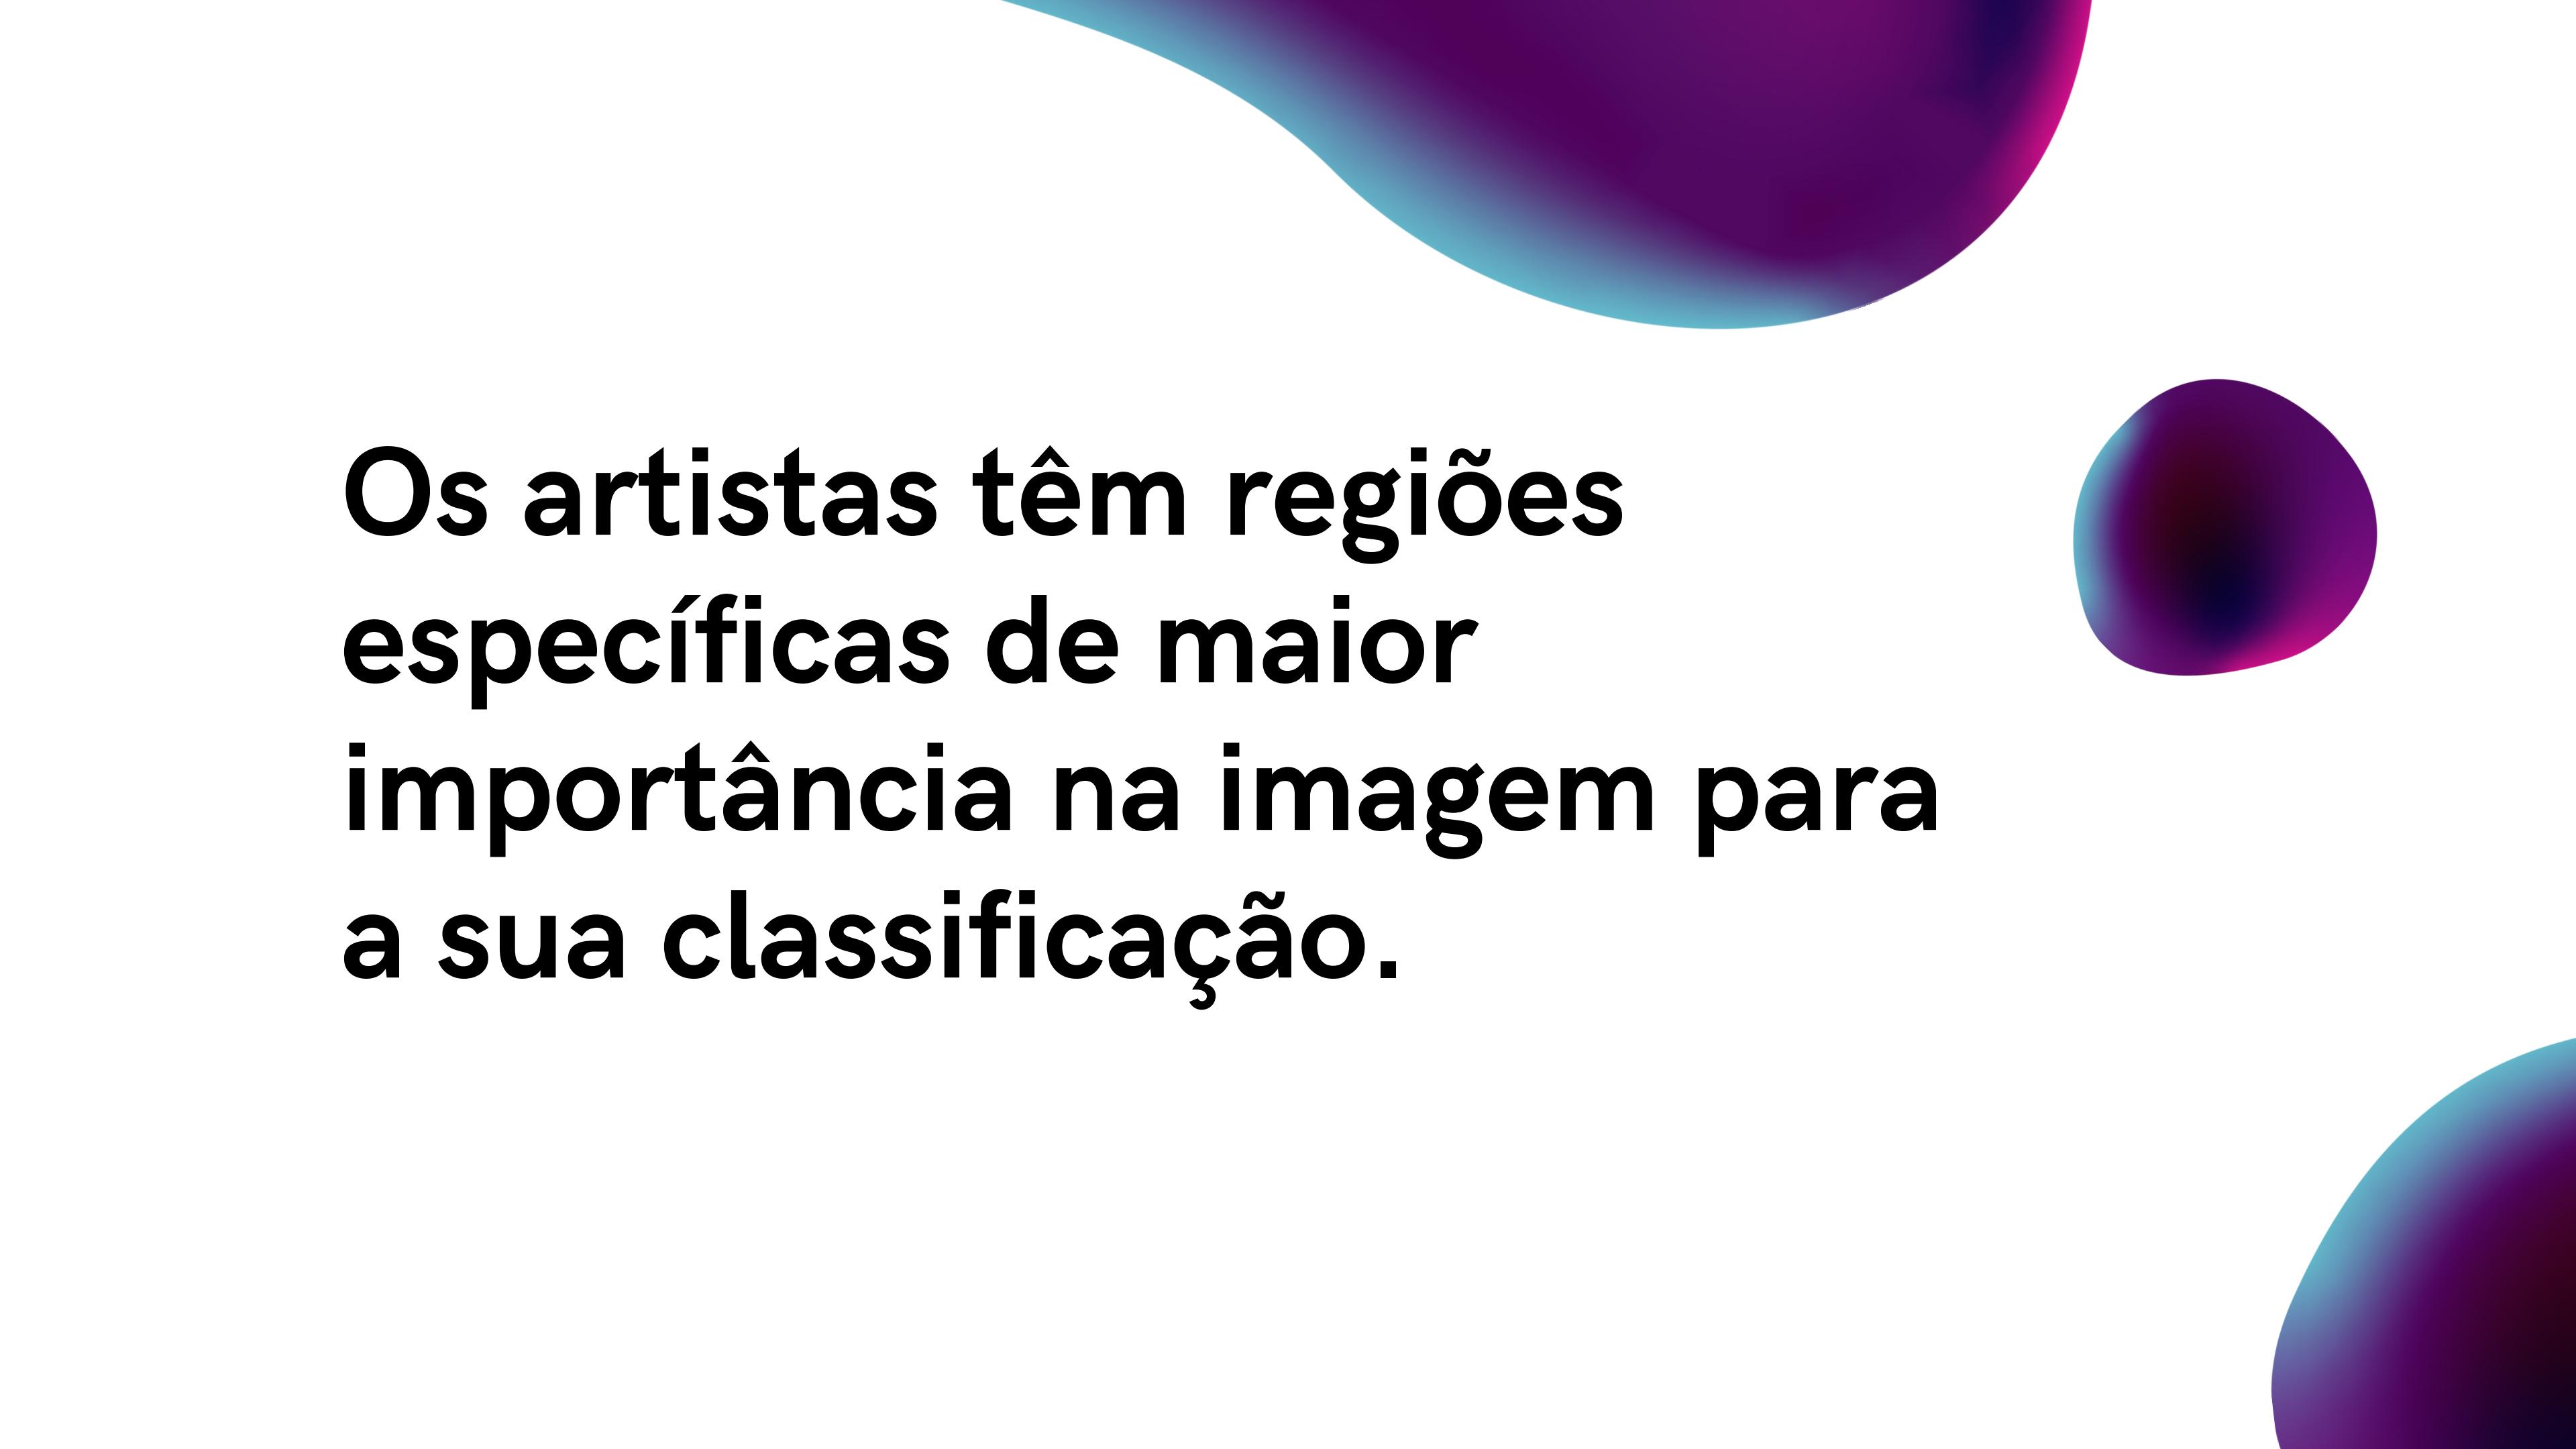
# Acurácia dos modelos





# Conclusão

**Stable Diffusion é  
consistente em criar o que  
acredita ser Monet e Renoir,  
porém não abstrai os  
verdadeiros aspectos**



**Os artistas têm regiões  
específicas de maior  
importância na imagem para  
a sua classificação.**



**A utilização de LLM's para Prompt  
Engineering de modelos de difusão  
como técnica de Data Augmentation  
não aparenta dar resultados  
melhores que apenas os dados reais.**

Agradecimentos ao Prof. Dr. Fábio  
Faria por ter orientado este trabalho, e  
ao Mateus M. Souza, por ter auxiliado  
gerando as imagens sintéticas pela  
Stable Diffusion.

# Perguntas